Karlsruher Institut für Technologie

Mathematik II für Wirtschaftsinformatik und Digital Economics

8. Kapitel Differenzierbarkeit in mehreren Veränderlichen: partielle Differenzierbarkeit

Daniel Weiß | 16.7.2025

Ausblick auf die heutige Vorlesung

- Differenzierbarkeit vektorwertiger Funktionen in einer Veränderlichen
- Partielle Differenzierbarkeit
- Gradient

Verallgemeinerung des Differenzierbarkeitskonzepts

$$f : \mathbb{R} \to \mathbb{R}$$

$$\mathbf{f} : \mathbb{R} \to \mathbb{R}^M, \quad x \mapsto \begin{pmatrix} f_1(x) \\ \vdots \\ f_M(x) \end{pmatrix}$$

$$f : \mathbb{R}^N \to \mathbb{R}, \quad \begin{pmatrix} x_1 \\ \vdots \\ x_N \end{pmatrix} \mapsto f(x_1, \ldots, x_N)$$

Verallgemeinerung des Differenzierbarkeitskonzepts

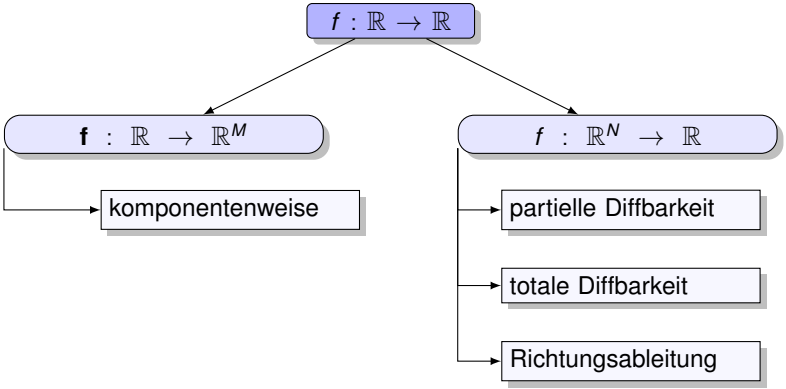

Folgerung: Dann auch bei $\mathbf{f} : \mathbb{R}^N \to \mathbb{R}^M$ komponentenweise.

Differenzierbarkeit vektorwertiger Funktionen in einer Veränderlichen

Definition

Eine vektorwertige Funktion $\mathbf{f}\colon \mathcal{I} \to \mathbb{R}^M$ heißt differenzierbar in $x \in \mathcal{I}$, wenn $\mathbf{f} = \begin{pmatrix} f_1 & \dots & f_M \end{pmatrix}^\top$ komponentenweise in x differenzierbar ist. Dabei ist $\mathcal{I}$ ein Intervall. Wir setzen dann

$$\mathbf{f}'(x) = \begin{pmatrix} f_1'(x) \\ \vdots \\ f_M'(x) \end{pmatrix}.$$

Die Funktion $\mathbf{f}$ ist differenzierbar, wenn $\mathbf{f}$ in allen Punkten $x \in \mathcal{I}$ differenzierbar ist.

Die Ableitung $\mathbf{f}' : \mathcal{I} \to \mathbb{R}^M$ ist eine vektorwertige Funktion in einer Veränderlichen.

Vorbereitende Interpretation

Gegeben: $f\colon \mathbb{R}^N \to \mathbb{R}$ und $\mathbf{x} \in \mathbb{R}^N$.

Betrachte: $g\colon \mathbb{R} \to \mathbb{R}, \quad t \mapsto g(t) := f(x_1, \ldots, x_{n-1}, x_n + t, x_{n+1}, \ldots, x_N)$.

Folgerung:

$$\begin{aligned} g'(0) &= \lim_{h \to 0} \frac{g(h) - g(0)}{h} \\ &= \lim_{h \to 0} \frac{f(x_1, \ldots, x_{n-1}, x_n + h, x_{n+1}, \ldots, x_N) - f(\mathbf{x})}{h} \\ &= \lim_{h \to 0} \frac{f(\mathbf{x} + h\mathbf{e}^n) - f(\mathbf{x})}{h} = \frac{\partial f}{\partial x_n}(\mathbf{x}). \end{aligned}$$

Partielle Differenzierbarkeit in einem Punkt

Definition

Eine Funktion $f\colon D \to \mathbb{R}$, $D \subseteq \mathbb{R}^N$ offen, heißt **partiell differenzierbar in $\mathbf{x} \in D$ nach x_n**, falls der Grenzwert

$$\frac{\partial f}{\partial x_n}(\mathbf{x}) := \lim_{h \to 0} \frac{f(\mathbf{x} + h\mathbf{e}^n) - f(\mathbf{x})}{h}$$

existiert.

Dann heißt $\frac{\partial f}{\partial x_n}(\mathbf{x})$ die **partielle Ableitung von f in $\mathbf{x}$ nach x_n**.

Bemerkung: Wir haben $\mathbf{e}^n$ verwendet, um nur in der n-te Komponente zu variieren.

Beispiele

- Für $f\colon \mathbb{R}^2 \to \mathbb{R}$ mit $f(x,y) = x\mathrm{e}^y + \sin(xy)$ gilt

$$\frac{\partial f}{\partial x}(x,y) = \mathrm{e}^y + y\cos(xy), \qquad \frac{\partial f}{\partial y}(x,y) = x\mathrm{e}^y + x\cos(xy).$$

- Für $f\colon \mathbb{R}^N \backslash \{\mathbf{0}\} \to \mathbb{R}$ mit $f(\mathbf{x}) = \|\mathbf{x}\|_2$ gilt

$$\frac{\partial f}{\partial x_n}(\mathbf{x}) = \frac{x_n}{\|\mathbf{x}\|_2}.$$

Partielle Differenzierbarkeit

Definition

Sei $D \subseteq \mathbb{R}^N$ offen.

(i) $f\colon D \to \mathbb{R}$, heißt **partiell differenzierbar in $\mathbf{x} \in D$**, falls alle partiellen Ableitungen von f nach x_n für $n = 1, \ldots, N$ in $\mathbf{x}$ existieren.

(ii) Ist $f\colon D \to \mathbb{R}$ in allen Punkten $\mathbf{x} \in D$ partiell differenzierbar nach x_n, so heißt f **partiell differenzierbar nach x_n**.

(iii) Trifft dies für alle Veränderlichen x_n, $n = 1, \ldots, N$, zu, so heißt f **partiell differenzierbar**.

(iv) Sind darüber hinaus alle partiellen Ableitungen stetig, so heißt f **stetig partiell differenzierbar** oder $C^1(D)$-Funktion.

Gradient

Definition

Sei $f\colon D \to \mathbb{R}$ partiell differenzierbar in $\mathbf{x}$. Dann heißt der Zeilenvektor

$$\operatorname{grad} f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}(\mathbf{x}), \ldots, \frac{\partial f}{\partial x_N}(\mathbf{x})\right)$$

der **Gradient von f in $\mathbf{x}$**.

Bemerkung: Auch sehr gebräuchlich ist der Spaltenvektor (gesprochen „Nabla f“)

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}(\mathbf{x}), \ldots, \frac{\partial f}{\partial x_N}(\mathbf{x})\right)^\top .$$

Beispiele

- Für $f\colon \mathbb{R}^2 \to \mathbb{R}$ mit $f(x,y) = \mathrm{e}^{xy^2}\cos y$ lautet der Gradient

$$\operatorname{grad} f(x,y) = \mathrm{e}^{xy^2}\left(y^2\cos y, 2xy\cos y - \sin y\right).$$

- Für $r\colon \mathbb{R}^N\backslash\{\mathbf{0}\} \to \mathbb{R}$ mit $r(\mathbf{x}) = \|\mathbf{x}\|_2$ lautet der Gradient $\operatorname{grad} r(\mathbf{x}) = \dfrac{\mathbf{x}^\top}{\|\mathbf{x}\|_2}$.

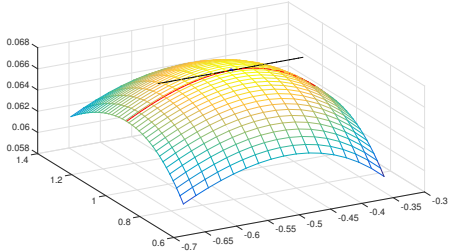

Beispiele

- Sei $\mathbf{c} \in \mathbb{R}^N$. Für die lineare Funktion $g\colon \mathbb{R}^N \to \mathbb{R}$ definiert durch $\mathbf{x} \mapsto \mathbf{c}^\top \mathbf{x} = \mathbf{x}^\top \mathbf{c}$ gilt $\operatorname{grad} g(x) = \mathbf{c}^\top$.

- Sei $A \in \mathbb{R}^{N \times N}$. Für die quadratische Funktion $q\colon \mathbb{R}^N \to \mathbb{R}$ definiert durch $\mathbf{x} \mapsto \mathbf{x}^\top A\mathbf{x} = \sum_{m,n=1}^{N} a_{mn} x_m x_n$ gilt

$$\operatorname{grad} q(\mathbf{x}) = \mathbf{x}^\top (A + A^\top).$$

Bemerkung: Ist A symmetrisch, so gilt $\operatorname{grad} q(\mathbf{x}) = 2\mathbf{x}^\top A$.

Karlsruher Institut für Technologie

Mathematik II für Wirtschaftsinformatik und Digital Economics

8. Kapitel Differenzierbarkeit in mehreren Veränderlichen: notwendige/hinreichende Bedingung für Extrema

Daniel Weiß | 21.7.2025

Ausblick auf die heutige Vorlesung

- Notwendige Bedingung für ein Extremum
- Höhere partielle Ableitungen und Hesse-Matrix
- Definitheit der Hesse-Matrix in kritischem Punkt
- Aus partieller Differenzierbarkeit folgt nicht Stetigkeit

Notwendige Bedingung für ein Extremum

Satz

Sei $D \subseteq \mathbb{R}^N$ offen und sei $f\colon D \to \mathbb{R}$ partiell differenzierbar.

Besitzt f in $\mathbf{x}_* \in D$ ein lokales Extremum, so gilt $\operatorname{grad} f(\mathbf{x}_*) = \mathbf{0}^\top$.

Bemerkung:

- Wir nennen Vektoren $\mathbf{x}$ mit $\operatorname{grad} f(\mathbf{x}) = \mathbf{0}^\top$ kritische Punkte von f.
- Maxima, Minima und Sattelpunkte sind kritische Punkte einer reellwertigen Funktion.
- $f\colon D \to \mathbb{R}$ besitzt einen Sattelpunkt in $\mathbf{x}$, wenn in jeder Umgebung von $\mathbf{x}$ in D Vektoren $\mathbf{v}, \mathbf{w}$ mit $f(\mathbf{v}) < f(\mathbf{x}) < f(\mathbf{w})$ existieren.

Quadratische Minimierung ohne Nebenbedingung

Betrachte für symmetrische Matrix $A \in \mathbb{R}^{N\times N}$: $f\colon \mathbb{R}^N \to \mathbb{R}$ mit $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top A\mathbf{x} + \mathbf{c}^\top\mathbf{x} + d$.

Spezialfalll: $f(\mathbf{x}) = \frac{1}{2}\|B\mathbf{x} - \mathbf{b}\|_2^2$ mit $B \in \mathbb{R}^{M\times N}$ und $\mathbf{b} \in \mathbb{R}^M$.

Gradient: $\operatorname{grad} f(\mathbf{x}) = (\mathbf{x}^\top B^\top - \mathbf{b}^\top)B$.

Kritischer Punkt: $\operatorname{grad} f(\mathbf{x}) = \mathbf{0}^\top$.

Bemerkung: Für kritische Punkte liegt der Vektor $B\mathbf{x} - \mathbf{b}$ im Kern der Matrix $B^\top$.

Rechenregeln für partielle Ableitungen

Satz

Seien $f, g\colon D \to \mathbb{R}$, $D \subset \mathbb{R}^N$, partiell differenzierbar. Dann gilt:

(i) $\frac{\partial(fg)}{\partial x_n} = \frac{\partial f}{\partial x_n} g + f \frac{\partial g}{\partial x_n}$

(ii) $\frac{\partial}{\partial x_n} \frac{f}{g} = \frac{1}{g^2} \left(\frac{\partial f}{\partial x_n} g - f \frac{\partial g}{\partial x_n} \right)$

(iii) $\frac{\partial(f \circ g)}{\partial x_n} = (f' \circ g) \frac{\partial g}{\partial x_n}$ (hier ist $f\colon \mathbb{R} \to \mathbb{R}$)

(iv) $\frac{\partial}{\partial x_n}(\mu f + \lambda g) = \mu \frac{\partial f}{\partial x_n} + \lambda \frac{\partial g}{\partial x_n}$ für $\lambda, \mu \in \mathbb{R}$.

Rechenregeln für den Gradienten

Satz

Seien $f, g\colon D \to \mathbb{R}$, $D \subset \mathbb{R}^N$, partiell differenzierbar. Dann gilt:

(i) $\operatorname{grad}(fg) = g \operatorname{grad} f + f \operatorname{grad} g$

(ii) $\operatorname{grad}\left(\frac{f}{g}\right) = \frac{1}{g^2}(g \operatorname{grad} f - f \operatorname{grad} g)$

(iii) $\operatorname{grad}(f \circ g) = (f' \circ g) \operatorname{grad} g$ (hier ist $f\colon \mathbb{R} \to \mathbb{R}$)

(iv) $\operatorname{grad}(\mu f + \lambda g) = \mu \operatorname{grad} f + \lambda \operatorname{grad} g$ für $\lambda, \mu \in \mathbb{R}$.

Höhere partielle Ableitungen

Definition

Sei $f\colon D \to \mathbb{R}$ partiell differenzierbar.

Falls die partiellen Ableitungen wieder partiell differenzierbar sind, definieren wir

(i) $\frac{\partial^2 f}{\partial x_j \partial x_n} := \frac{\partial}{\partial x_j}\left(\frac{\partial f}{\partial x_n}\right)$ und $\frac{\partial^2 f}{\partial x_j^2} := \frac{\partial}{\partial x_j}\left(\frac{\partial f}{\partial x_j}\right)$,

(ii) $\frac{\partial^k f}{\partial x_{n_k} \partial x_{n_{k-1}} \dots \partial x_{n_1}} := \frac{\partial}{\partial x_{n_k}}\left(\frac{\partial^{k-1} f}{\partial x_{n_{k-1}} \dots \partial x_{n_1}}\right)$.

Die Funktion f heißt k-fach partiell differenzierbar, falls alle partiellen Ableitungen bis zur Ordnung k auf D existieren.

Sind diese Ableitungen stetig, so heißt f k-fach stetig partiell differenzierbar oder $C^k(D)$-Funktion.

Hesse-Matrix

Definition

Sei $D \subseteq \mathbb{R}^N$ offen und sei $f \in C^2(D)$.

Die **Hesse-Matrix** von f in $\mathbf{x} \in D$ ist die $(N \times N)$-Matrix

$$H_f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_N}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_N}(\mathbf{x}) \\ \vdots & \vdots & & \vdots \\ \frac{\partial^2 f}{\partial x_N \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_N \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_N^2}(\mathbf{x}) \end{pmatrix}.$$

Beispiele

- Für $f\colon \mathbb{R}^2 \to \mathbb{R}$, $f(x,y) = xe^y + \sin(xy)$ gilt

$$H_f(x,y) = \begin{pmatrix} -y^2\sin(xy) & \mathrm{e}^y + \cos(xy) - xy\sin(xy) \\ \mathrm{e}^y + \cos(xy) - xy\sin(xy) & x\mathrm{e}^y - x^2\sin(xy) \end{pmatrix}.$$

- **Minimiere:** $f(\mathbf{x}) = \frac{1}{2}\|B\mathbf{x} - \mathbf{b}\|_2^2$ mit $B \in \mathbb{R}^{M\times N}$ und $\mathbf{b} \in \mathbb{R}^M$.

  Gradient: $\operatorname{grad} f(\mathbf{x}) = (\mathbf{x}^\top B^\top - \mathbf{b}^\top)B$.

  Hesse-Matrix: $H_f(\mathbf{x}) = B^\top B$. Beachte $\frac{\partial f}{\partial x_n}(\mathbf{x}) = (\mathbf{x}^\top B^\top - \mathbf{b}^\top)B\mathbf{e}^n$.

Satz von Schwarz

Satz

Für $f \in C^k(D)$ sind alle partiellen Ableitungen bis zur Ordnung k unabhängig von der Reihenfolge der Differentiation.

Beispiel: Für die folgende Funktion gilt $\frac{\partial^2 f}{\partial x \partial y}(0,0) \neq \frac{\partial^2 f}{\partial y \partial x}(0,0)$

$$f\colon \mathbb{R}^2 \to \mathbb{R}, \qquad f(x,y) = \begin{cases} xy\frac{x^2-y^2}{x^2+y^2} & \text{für } (x,y) \neq \mathbf{0}, \\ 0 & \text{für } (x,y) = \mathbf{0}. \end{cases}$$

Beachte: $f \notin C^2(\mathbb{R}^2)$.

Definitheit der Hesse-Matrix in kritischem Punkt

Satz

Sei $f \in C^2(D)$ und $\mathbf{x} \in D$ mit $\operatorname{grad} f(\mathbf{x}) = \mathbf{0}^\top$.

(i) Ist $H_f(\mathbf{x})$ positiv definit, so besitzt f in $\mathbf{x}$ ein lokales Minimum.

(ii) Ist $H_f(\mathbf{x})$ negativ definit, so besitzt f in $\mathbf{x}$ ein lokales Maximum.

(iii) Ist $H_f(\mathbf{x})$ indefinit, d. h. es existieren $\mathbf{y}, \mathbf{z} \in \mathbb{R}^N$ mit $\mathbf{y}^\top H_f(\mathbf{x})\mathbf{y} < 0$ und $\mathbf{z}^\top H_f(\mathbf{x})\mathbf{z} > 0$, so liegt bei $\mathbf{x}$ ein Sattelpunkt von f vor.

Bemerkung: Beweis basiert auf der Taylorentwicklung in mehreren Veränderlichen 2. Ordnung

$$f(\mathbf{x}) = f(\mathbf{x}_*) + \operatorname{grad} f(\mathbf{x}_*)(\mathbf{x} - \mathbf{x}_*) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_*)^\top H_f(\mathbf{x}_*)(\mathbf{x} - \mathbf{x}_*) + o(\|\mathbf{x} - \mathbf{x}_*\|^2).$$

Bemerkungen zur Definitheit der Hesse-Matrix

Sei $H \in \mathbb{R}^{N \times N}$ symmetrisch.

Wir wissen aus Mathematik I:

- H ist genau dann positiv (negativ) definit ist, wenn alle Eigenwerte positiv (negativ) sind.
- H ist genau dann positiv (negativ) semidefinit ist, wenn alle Eigenwerte nicht-negativ (nicht-positiv) sind.
- H ist genau dann indefinit, wenn sie zwei Eigenwerte mit unterschiedlichen Vorzeichen besitzt.

Wiederholung des Beispiels zur Minimierung

quadratische Minimierung: Sei $B \in \mathbb{R}^{M \times N}$ und $\mathbf{b} \in \mathbb{R}^M$. Suche Minimum von $f\colon \mathbb{R}^N \to \mathbb{R}$ definiert durch

$$f(\mathbf{x}) = \tfrac{1}{2}\|B\mathbf{x} - \mathbf{b}\|_2^2.$$

Gradient: $\operatorname{grad} f(\mathbf{x}) = (\mathbf{x}^\top B^\top - \mathbf{b}^\top)B.$

Kritischer Punkt: $\operatorname{grad} f(\mathbf{x}) = \mathbf{0}^\top.$

Hesse-Matrix: $H_f(\mathbf{x}) = B^\top B$ ist genau dann positiv definit, wenn B maximalen Rang hat.

Aus partieller Differenzierbarkeit folgt nicht Stetigkeit

Die Funktion in zwei Veränderlichen $f\colon \mathbb{R}^2 \to \mathbb{R}$,

$$f(x,y) = \begin{cases} \frac{xy}{(x^2+y^2)^2} & \text{für } (x,y) \neq \mathbf{0}, \\ 0 & \text{für } (x,y) = \mathbf{0}, \end{cases}$$

ist partiell differenzierbar, aber nicht stetig.

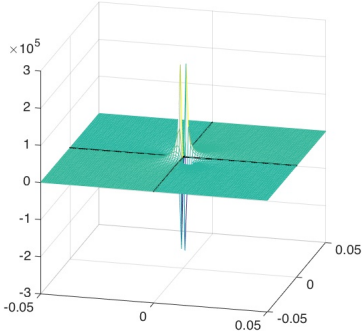

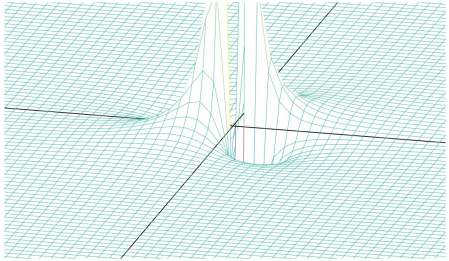

Partielle Differenzierbarkeit vektorwertiger Funktionen

Definition

Sei $D \subseteq \mathbb{R}^N$ offen. Die partielle Differenzierbarkeit von $\mathbf{f}\colon D \to \mathbb{R}^M$ ist über die Komponentenfunktionen $f_m\colon D \to \mathbb{R}$ für $m = 1, \ldots, M$ definiert.

Folgerung: Einige Definitionen und Sätze (nicht die über Extrema) lassen sich komponentenweise übertragen.

Karlsruher Institut für Technologie

Mathematik II für Wirtschaftsinformatik und Digital Economics

8. Kapitel Differenzierbarkeit in mehreren Veränderlichen: Totale Differenzierbarkeit

Daniel Weiß | 23.7.2025

Ausblick auf die heutige Vorlesung

- Totale Differenzierbarkeit
- Zusammenhang der Diffbarkeitskonzepte
- Kettenregel

Wiederholung Kapitel 6

- Ist $f\colon \mathcal{I} \to \mathbb{R}$ differenzierbar in $x_* \in \mathcal{I}$, so gilt $\lim_{x\to x_*} \frac{f(x)-f(x_*)}{x-x_*} = f'(x_*)$.

- Dies ist äquivalent zu

$$\lim_{x\to x_*} \frac{f(x) - T(x)}{|x - x_*|} = 0 \quad \text{mit} \quad T(x) = f(x_*) + f'(x_*)(x - x_*).$$

Bedeutung: Wir können f lokal bei $x = x_*$ mit einer gewissen Güte durch die Tangentenfunktion T approximieren.

Totale Differenzierbarkeit

Definition

$\mathbf{f}\colon D \to \mathbb{R}^M$ heißt **(total) differenzierbar in** $\mathbf{x}_* \in D$, $D \subseteq \mathbb{R}^N$ offen, falls $A = A(\mathbf{x}_*) \in \mathbb{R}^{M\times N}$ existiert mit

$$\lim_{\mathbf{x}\to\mathbf{x}_*} \frac{\mathbf{f}(\mathbf{x}) - \mathbf{f}(\mathbf{x}_*) - A(\mathbf{x}-\mathbf{x}_*)}{\|\mathbf{x}-\mathbf{x}_*\|} = \mathbf{0} \in \mathbb{R}^M.$$

Dabei ist $\|\cdot\|$ eine beliebige Norm auf $\mathbb{R}^N$.

A heißt **Jacobi-Matrix** von $\mathbf{f}$ in $\mathbf{x}_*$, Bezeichnung für die Jacobi-Matrix: $\mathbf{f}'(\mathbf{x}_*)$ oder $\mathrm{D}\mathbf{f}(\mathbf{x}_*)$.

Ist $\mathbf{f}$ für alle $\mathbf{x} \in D$ differenzierbar, so heißt $\mathbf{f}$ differenzierbar und $\mathbf{f}'\colon D \to \mathbb{R}^{M\times N}, \mathbf{x} \mapsto A(\mathbf{x})$ die erste Ableitung von $\mathbf{f}$.

Bemerkung: Der Wertebereich der Ableitung stimmt für $N > 1$ nicht mit dem von $\mathbf{f}$ überein.

Charakterisierung der Differenzierbarkeit

Satz

Sei $D \subseteq \mathbb{R}^N$ offen.

Die Funktion $\mathbf{f}\colon D \to \mathbb{R}^M$ ist genau dann differenzierbar, wenn die Komponentenfunktionen $f_m\colon D \to \mathbb{R}$ für alle $m = 1, \ldots, M$ differenzierbar sind.

In diesem Fall gilt:

$$\mathbf{f}'(\mathbf{x}) = \begin{pmatrix} f_1'(\mathbf{x}) \\ \vdots \\ f_M'(\mathbf{x}) \end{pmatrix} \in \mathbb{R}^{M \times N}, \qquad f_m'(\mathbf{x}) \in \mathbb{R}^{1 \times N}.$$

Aus totaler Differenzierbarkeit folgt Stetigkeit

Satz

Sei $\mathbf{f}\colon D \to \mathbb{R}^M$, $D \subseteq \mathbb{R}^N$ offen, und sei $\mathbf{x}_* \in D$. Ist $\mathbf{f}$ in $\mathbf{x}_*$ differenzierbar, so ist $\mathbf{f}$ dort auch stetig.

Aus totaler folgt partielle Differenzierbarkeit

Satz

Sei $\mathbf{f}\colon D \to \mathbb{R}^M$, $D \subseteq \mathbb{R}^N$ offen, und sei $\mathbf{x} \in D$.

Ist $\mathbf{f}$ in $\mathbf{x}$ differenzierbar, so ist $\mathbf{f}$ dort auch partiell differenzierbar und für die Jacobi-Matrix gilt:

$$\mathbf{f}'(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial f_1}{\partial x_N}(\mathbf{x}) \\ \vdots & & \vdots \\ \frac{\partial f_M}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial f_M}{\partial x_N}(\mathbf{x}) \end{pmatrix} = \begin{pmatrix} \operatorname{grad} f_1(\mathbf{x}) \\ \vdots \\ \operatorname{grad} f_M(\mathbf{x}) \end{pmatrix}.$$

Beispiele für die Jacobi-Matrix

Funktion: $f\colon \mathbb{R}^2 \to \mathbb{R}^2$ mit $\mathbf{f}(x,y) = \begin{pmatrix} x\mathrm{e}^y + \sin(xy) \\ \mathrm{e}^{xy^2}\cos y \end{pmatrix}$.

Jacobi-Matrix: $\mathbf{f}'(x,y) = \begin{pmatrix} \mathrm{e}^y + y\cos(xy) & x\mathrm{e}^y + x\cos(xy) \\ \mathrm{e}^{xy^2}y^2\cos y & \mathrm{e}^{xy^2}(2xy\cos y - \sin y) \end{pmatrix}$.

Aktivierungsfunktion: $\boldsymbol{\sigma}\colon \mathbb{R}^N \to \mathbb{R}^N, \qquad \mathbf{x} \mapsto \boldsymbol{\sigma}(\mathbf{x}) := \begin{pmatrix} \sigma(x_1) \\ \vdots \\ \sigma(x_N) \end{pmatrix}$ mit $\sigma\colon \mathbb{R} \to \mathbb{R}$

Jacobi-Matrix: $\boldsymbol{\sigma}'(\mathbf{x}) = \operatorname{diag}(\sigma'(x_1), \ldots, \sigma'(x_N))$

Aus stetig partieller Differenzierbarkeit folgt stetige Differenzierbarkeit

Satz

Gegeben sei eine Abbildung $\mathbf{f}\colon D \to \mathbb{R}^M$, $D \subseteq \mathbb{R}^N$ offen.

Ist $\mathbf{f} \in C^1(D)$, so ist $\mathbf{f}$ auf D auch stetig differenzierbar.

Zusammenhang der Diffbarkeitskonzepte

stetig partiell differenzierbar $\Leftrightarrow$ stetig differenzierbar

differenzierbar $\Rightarrow$ partiell differenzierbar.

Die Umkehrung gilt nicht (siehe Beispiel oben)!

Kettenregel

Satz

Sei $\mathbf{f}\colon D \to \mathbb{R}^M$ differenzierbar in $\mathbf{x}_* \in D \subseteq \mathbb{R}^N$, D offen, und sei $\mathbf{g}\colon E \to \mathbb{R}^K$ differenzierbar in $\mathbf{y}_* = \mathbf{f}(\mathbf{x}_*) \in E$, $E \subseteq \mathbb{R}^M$ offen und $f(D) \subseteq E$.

Dann ist $\mathbf{g} \circ \mathbf{f}\colon D \to \mathbb{R}^K$ differenzierbar in $\mathbf{x}_*$ mit

$$\underbrace{(\mathbf{g} \circ \mathbf{f})'(\mathbf{x}_*)}_{\in \mathbb{R}^{K \times N}} = \underbrace{\mathbf{g}'(\mathbf{f}(\mathbf{x}_*))}_{\in \mathbb{R}^{K \times M}} \underbrace{\mathbf{f}'(\mathbf{x}_*)}_{\in \mathbb{R}^{M \times N}}.$$

Karlsruher Institut für Technologie

Mathematik II für Wirtschaftsinformatik und Digital Economics

8. Kapitel Differenzierbarkeit in mehreren Veränderlichen: Anwendung der Kettenregel, Richtungsableitung

Daniel Weiß | 28.7.2025

Ausblick auf die heutige Vorlesung

- Wiederholung der Kettenregel
- Anwendung der Kettenregel bei Multi-Layer Perceptrons
- Richtungsableitung

Wiederholung: Kettenregel

Satz

Sei $\mathbf{f}\colon D \to \mathbb{R}^M$ differenzierbar in $\mathbf{x}_* \in D \subseteq \mathbb{R}^N$, D offen, und sei $\mathbf{g}\colon E \to \mathbb{R}^K$ differenzierbar in $\mathbf{y}_* = \mathbf{f}(\mathbf{x}_*) \in E$, $E \subseteq \mathbb{R}^M$ offen und $f(D) \subseteq E$. Dann ist $\mathbf{g} \circ \mathbf{f}\colon D \to \mathbb{R}^K$ differenzierbar in $\mathbf{x}_*$ mit

$$\underbrace{(\mathbf{g} \circ \mathbf{f})'(\mathbf{x}_*)}_{\in \mathbb{R}^{K \times N}} = \underbrace{\mathbf{g}'(\mathbf{f}(\mathbf{x}_*))}_{\in \mathbb{R}^{K \times M}} \underbrace{\mathbf{f}'(\mathbf{x}_*)}_{\in \mathbb{R}^{M \times N}}.$$

Wichtige Anwendungen: Der Fall $K = 1$

$$\operatorname{grad}(g \circ \mathbf{f})(\mathbf{x}_*) = \operatorname{grad} g(\mathbf{f}(\mathbf{x}_*))\mathbf{f}'(\mathbf{x}_*)$$

und komponentenweise für die einzelnen partiellen Ableitungen

$$\frac{\partial(g \circ \mathbf{f})}{\partial x_n}(\mathbf{x}_*) = \operatorname{grad} g(\mathbf{f}(\mathbf{x}_*))\frac{\partial \mathbf{f}}{\partial x_n}(\mathbf{x}_*).$$

Künstliche neuronale Netzen

Verwendung: Es soll eine unbekannte Funktion $\mathbf{f}\colon \mathbb{R}^N \to \mathbb{R}^M$ approximiert werden.

Supervised Learning: Es sind Daten $(\mathbf{x}^n, \mathbf{y}^n) \in \mathbb{R}^N \times \mathbb{R}^M$ mit $\mathbf{f}(\mathbf{x}^n) = \mathbf{y}^n$ für $n = 1, \ldots, K$ bekannt.

Ziel: Bestimme anhand der Trainingsdaten eine Approximation $\mathbf{f}_{\boldsymbol{\theta}_*} \in \{\mathbf{f}_{\boldsymbol{\theta}} : \boldsymbol{\theta} \in \mathbb{R}^D\}$ (oft D sehr groß).

Generalisierung: $\mathbf{f}(\mathbf{x}) \approx \mathbf{f}_{\boldsymbol{\theta}_*}(\mathbf{x})$ auch für $\mathbf{x}$, wenn $\mathbf{x}$ kein Trainingsdatenpunkt ist.

Multi-Layer Perceptron

Ein Multi-Layer Perceptron (ein einfaches Feed-Forward-Netzwerk) bildet $\mathbf{x} \in \mathbb{R}^{N_0}$ auf $\mathbf{h}^L \in \mathbb{R}^{N_L}$ ab.

Hidden States: Mit $L \in \mathbb{N}$, $N_\ell \in \mathbb{N}$, $W_\ell \in \mathbb{R}^{N_\ell \times N_{\ell-1}}$ und $\mathbf{b}^\ell \in \mathbb{R}^{N_\ell}$ für $\ell = 1, \ldots, L$ berechne

$$\mathbf{h}^0 = \mathbf{x}, \qquad \mathbf{h}^\ell = \sigma(W_\ell \mathbf{h}^{\ell-1} + \mathbf{b}^\ell) \in \mathbb{R}^{N_\ell}, \quad \ell = 1, \ldots, L.$$

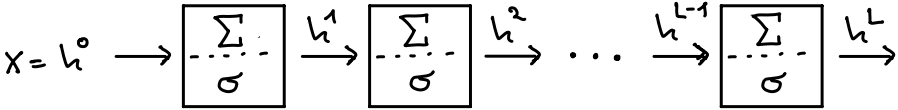

Präaktivierungsvektoren: $\mathbf{z}^\ell = W_\ell \mathbf{h}^{\ell-1} + \mathbf{b}^\ell$.

Kostenfunktion: $C \colon \mathbb{R}^{N_L} \to \mathbb{R}$, $\mathbf{h}^L \mapsto C(\mathbf{h}^L)$.

Ziel: Finde Gewichte und Biasvektoren, so dass Kosten minimal.

Anwendung der Kettenregel bei Multi-Layer Perceptron

Wiederholung: $\mathbf{h}^0 = \mathbf{x}, \qquad \mathbf{z}^\ell = W_\ell \mathbf{h}^{\ell-1} + \mathbf{b}^\ell, \qquad \mathbf{h}^\ell = \sigma(\mathbf{z}^\ell) \in \mathbb{R}^{N_\ell}, \quad \ell = 1, \ldots, L.$

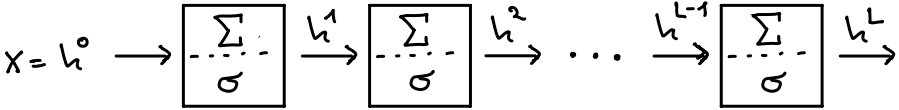

Frage: Wie ändern sich die Kosten bei Variation von $\mathbf{z}^\ell$?

Definitionen: Funktionen $\mathbf{h}_\ell^L \colon \mathbb{R}^{N_\ell} \to \mathbb{R}^{N_L}$ mit $\mathbf{h}_\ell^L(\mathbf{z}^\ell) = \mathbf{h}^L$ für $\ell = 1, \ldots, L$ „backwards“ durch

$$\mathbf{h}_L^L(\mathbf{z}) = \sigma(\mathbf{z}), \qquad \mathbf{h}_{\ell-1}^L(\mathbf{z}) = \mathbf{h}_\ell^L(W_\ell \sigma(\mathbf{z}) + \mathbf{b}^\ell), \quad \ell = L, \ldots, 2,$$

und die Gradienten $(\boldsymbol{\delta}^\ell)^\top = \operatorname{grad}(C \circ \mathbf{h}_\ell^L)(\mathbf{z}^\ell), \quad \ell = 1, \ldots, L.$

Folgerung: $(\boldsymbol{\delta}^L)^\top = \operatorname{grad} C(\mathbf{h}^L)\boldsymbol{\sigma}'(\mathbf{z}^L)$ und $(\boldsymbol{\delta}^{\ell-1})^\top = (\boldsymbol{\delta}^\ell)^\top W_\ell \boldsymbol{\sigma}'(\mathbf{z}^{\ell-1})$ für $\ell = L, \ldots, 2.$

Richtungsableitung

Definition

Sei $f\colon D \to \mathbb{R}$, $D \subseteq \mathbb{R}^N$ offen, $\mathbf{x} \in D$ und $\mathbf{v} \in \mathbb{R}^N$ ein Vektor. Falls der Grenzwert

$$\frac{\partial f}{\partial \mathbf{v}}(\mathbf{x}) := \lim_{h \to 0} \frac{f(\mathbf{x} + h\mathbf{v}) - f(\mathbf{x})}{h}$$

existiert, heißt er **Richtungsableitung** von f in $\mathbf{x}$ in Richtung $\mathbf{v}$.

Bemerkung:

Für $\mathbf{v} = \mathbf{e}^n$ stimmt diese Ableitung mit der n-ten partiellen Ableitung überein.

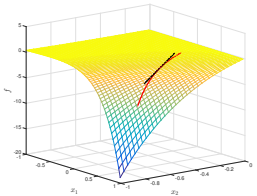

Richtungsableitung und Gradient

Karlsruher Institut für Technologie

Lemma

Sei $f\colon D \to \mathbb{R}$, $D \subseteq \mathbb{R}^N$ offen, differenzierbar in $\mathbf{x} \in D$.

Dann gilt für alle $\mathbf{v} \in \mathbb{R}^N$

$$\frac{\partial f}{\partial \mathbf{v}}(\mathbf{x}) = \operatorname{grad} f(\mathbf{x})\mathbf{v}.$$

Korollar: Sei $D \subseteq \mathbb{R}^N$ offen und sei $f\colon D \to \mathbb{R}$ differenzierbar. Besitzt f in $\mathbf{x}_* \in D$ ein lokales Extremum, so gilt für alle $\mathbf{v} \in \mathbb{R}^N$

$$\frac{\partial f}{\partial \mathbf{v}}(\mathbf{x}_*) = 0.$$

Steigung in Richtung v

Für $\lambda \neq 0$ gilt

$$\frac{\partial f}{\partial(\lambda \mathbf{v})}(\mathbf{x}) = \lambda \frac{\partial f}{\partial \mathbf{v}}(\mathbf{x}).$$

Definition

Ist $\mathbf{v} \in \mathbb{R}^N \backslash \{\mathbf{0}\}$ mit $\|\mathbf{v}\|_2 = 1$, so bezeichnet $\frac{\partial f}{\partial \mathbf{v}}(\mathbf{x})$ die Steigung von f in $\mathbf{x}$ in Richtung $\mathbf{v}$.

Steilster Anstieg in Richtung des Gradienten

Korollar: Sei $f\colon D \to \mathbb{R}$, $D \subseteq \mathbb{R}^N$ offen, differenzierbar in $\mathbf{x} \in D$.
Dann zeigt der Gradient $\operatorname{grad} f(\mathbf{x})$ an der Stelle $\mathbf{x}$ in Richtung des steilsten Anstiegs von f.

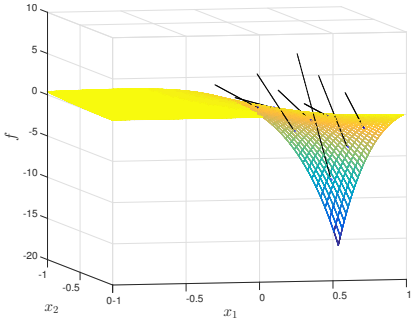

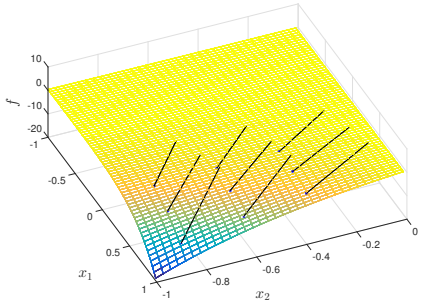

Bemerkung: Führt auf die Methode des steilsten Abstiegs zur Minimierung von Funktionen bzw. auf das Stochastische Gradientenverfahren beim Trainieren von Neuronalen Netzen.

Karlsruher Institut für Technologie

Mathematik II für Wirtschaftsinformatik und Digital Economics

8. Kapitel Differenzierbarkeit in mehreren Veränderlichen: Backpropagation, MWS

Daniel Weiß | 30.7.2025

Ausblick auf die heutige Vorlesung

- Backpropagation-Algorithmus
- Mittelwertsätze

Backpropagation-Algorithmus

1. **Input:** $\mathbf{x} = \mathbf{h}^0$
2. **Feedforward:** Für $\ell = 1, \ldots, L$ berechne $\mathbf{z}^\ell = W_\ell \mathbf{h}^{\ell-1} + \mathbf{b}^\ell$ und $\mathbf{h}^\ell = \boldsymbol{\sigma}(\mathbf{z}^\ell)$.
3. **Output deviation:** $\boldsymbol{\delta}^L = \nabla C(\mathbf{h}^L) \odot \boldsymbol{\sigma}'(\mathbf{z}^L)$.
4. **Backpropagate the deviation:** Für $\ell = L, \ldots, 2$ berechne $\boldsymbol{\delta}^{\ell-1} = W_\ell^\top \boldsymbol{\delta}^\ell \odot \boldsymbol{\sigma}'(\mathbf{z}^\ell)$.
5. **Output:** Partielle Ableitungen $\frac{\partial(C \circ \mathbf{h}_\ell^L \circ \mathbf{z}^\ell)}{\partial b_j^\ell}(b_j^\ell) = \delta_j^\ell$, $\frac{\partial(C \circ \mathbf{h}_\ell^L \circ \mathbf{z}^\ell)}{\partial w_{jk}^\ell}(w_{jk}^\ell) = \delta_j^\ell h_k^{\ell-1}$.

Bemerkung:

- Hier wird die diagonale Jacobi-Matrix $\boldsymbol{\sigma}'(\mathbf{z})$ als Spaltenvektor verstanden
- und durch $\odot$ komponentenweise multipliziert.

Mittelwertsatz in mehreren Veränderlichen

Satz

Sei $f\colon D \to \mathbb{R}$ auf $D \subseteq \mathbb{R}^N$ (offen) differenzierbar. Zu $\mathbf{x}, \mathbf{y} \in D$ liege die Verbindungsstrecke $\{\mathbf{x} + t(\mathbf{y} - \mathbf{x})\colon t \in [0,1]\}$ ebenfalls in D.

Dann existiert eine Zahl $\tilde{t} \in (0,1)$ mit

$$f(\mathbf{y}) - f(\mathbf{x}) = \operatorname{grad} f(\mathbf{x} + \tilde{t}(\mathbf{y} - \mathbf{x}))(\mathbf{y} - \mathbf{x}).$$

Beispiel: $f\colon \mathbb{R}^2 \to \mathbb{R}$, $\mathbf{x} \mapsto \cos x_1 + \sin x_2$ und $\mathbf{x} = (0,0)^\top$ und $\mathbf{y} = (\frac{\pi}{2}, \frac{\pi}{2})^\top$.

Beispiel für vektorwertige Funktionen

Wir betrachten $\mathbf{f}\colon \mathbb{R} \to \mathbb{R}^2$, $t \mapsto (\cos t, \sin t)^\top$. Es gilt:

$$\mathbf{f}(\tfrac{\pi}{2}) - \mathbf{f}(0) = \begin{pmatrix} 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Es gibt kein $\tilde{t} \in (0, 1)$ mit

$$\begin{pmatrix} -1 \\ 1 \end{pmatrix} = \mathbf{f}'\left(\tilde{t}\tfrac{\pi}{2}\right) \tfrac{\pi}{2}.$$

Folgerung: Der MWS für reellwertige Funktionen lässt sich nicht auf vektorwertige Funktionen übertragen.

Mittelwertabschätzungssatz

Satz

Sei $\mathbf{f}\colon D \to \mathbb{R}^M$ auf $D \subseteq \mathbb{R}^N$ (offen) differenzierbar. Zu $\mathbf{x}, \mathbf{y} \in D$ liege die Verbindungsstrecke $\{\mathbf{x} + t(\mathbf{y} - \mathbf{x})\colon t \in [0,1]\}$ ebenfalls in D.

Dann existiert eine Zahl $\tilde{t} \in (0,1)$ mit

$$\|\mathbf{f}(\mathbf{y}) - \mathbf{f}(\mathbf{x})\|_2 \leq \|\mathbf{f}'(\mathbf{x} + \tilde{t}(\mathbf{y} - \mathbf{x}))(\mathbf{y} - \mathbf{x})\|_2.$$